Predicción de Fuga de Clientes en el Sector de Automoción

Machine Learning + Estrategia Comercial Rentable

Caso Práctico de Inteligencia Artificial · Universidad Alfonso X el Sabio · 2026

Python · scikit-learn · SHAP · Plotly · Streamlit

Made with GAMMA

01 • EL PROBLEMA

Perder un cliente cuesta 5–7× más que retenerlo

El Problema

Un cliente en fuga lleva más de 400 días sin revisión técnica en taller oficial. Sin intervención, se pierde su ingreso de mantenimiento futuro (CLTV). Captar un cliente nuevo cuesta 5–7× más que retenerlo. El taller pierde no solo una revisión, sino toda la cadena futura.

Los Datos

58K
Registros Históricos
Sandbox de datos

44K
Clientes Únicos
Población activa

8.8%
Tasa de Churn
Ratio 10:1 desbalanceado

10K
Clientes Nuevos
Producción sin etiqueta

4.503.706 EUR en Revenue at Risk

Ingreso en riesgo sobre los 10.000 clientes en producción (horizonte 5 revisiones)

Hallazgos EDA Clave

Pico en la 2ª Revisión

22,1% de churn en la segunda revisión programada

Modelos C y A

Mayor tasa de churn (>13%) vs. Modelo H (~0%)

Fuera de Garantía

Aproximadamente 15% de churn en clientes sin cobertura

Queja Registrada

Mayor probabilidad de churn en clientes con incidencias

¿Podemos predecir quién se va antes de que ocurra?

Made with GAMMA

02 • EL MODELO

Random Forest: detectamos al 71% de los clientes en riesgo

Pipeline de Entrenamiento

1 — **Limpieza**

2 — **EDA**

3 — **Feature Engineering**
64 variables

4 — **4 Algoritmos**
CV 5-Fold

5 — **Random Forest ★**

Variables de revisiones y temporales excluidas para evitar quasi-leakage. Entrenado sobre población activa (Rev ≥ 1).

Comparación de Modelos

Modelo	AUC-PR (CV)	Desv. Std	Rank
Logistic Regression	0,346	± 0,012	2
Decision Tree	0,320	± 0,006	4
Random Forest ★	**0,355**	± 0,013	**1**
XGBoost	0,339	± 0,006	3

Se usa AUC-PR (no AUC-ROC) como métrica de selección porque el dataset está fuertemente desbalanceado (ratio 10:1). AUC-PR penaliza más los falsos negativos en la clase minoritaria.

Key Performance Indicators

78.9%
AUC-ROC

71%
Recall
Detectamos 7 de cada 10 churners

34.2%
Precision
1 de cada 3 alertas es churn real

46.2%
F1-Score

49.8%
Threshold Óptimo
Optimizado sobre curva F1

Trade-off Precision/Recall

Precisión del 34% = por cada 3 clientes alertados, 1 es churn real. Preferimos contactar de más antes que perder un cliente. El coste de un falso positivo (contacto innecesario) es mucho menor que el coste de un falso negativo (cliente perdido).

Sabemos quién se va. Pero ¿qué aprendió el modelo y cómo lo verificamos?

Made with GAMMA

02 · EL MODELO

Random Forest: detectamos al 71% de los clientes en riesgo

Pipeline de Entrenamiento

1. **Limpieza**
2. **EDA**
3. **Feature Engineering**
   64 variables
4. **4 Algoritmos**
   CV 5-Fold
5. **Random Forest ★**

Variables de revisiones y temporales excluidas para evitar quasi-leakage. Entrenado sobre población activa (Rev ≥ 1).

Comparación de Modelos

Modelo	AUC-PR (CV)	Desv. Std	Rank
Logistic Regression	0,346	± 0,012	2
Decision Tree	0,320	± 0,006	4
Random Forest ★	**0,355**	± 0,013	**1**
XGBoost	0,339	± 0,006	3

Se usa AUC-PR (no AUC-ROC) como métrica de selección porque el dataset está fuertemente desbalanceado (ratio 10:1). AUC-PR penaliza más los falsos negativos en la clase minoritaria.

Key Performance Indicators

78.9%
AUC-ROC

71%
Recall
Detectamos 7 de cada 10 churners

34.2%
Precision
1 de cada 3 alertas es churn real

46.2%
F1-Score

49.8%
Threshold Óptimo
Optimizado sobre curva F1

Trade-off Precision/Recall

Precisión del 34% = por cada 3 clientes alertados, 1 es churn real. Preferimos contactar de más antes que perder un cliente. El coste de un falso positivo (contacto innecesario) es mucho menor que el coste de un falso negativo (cliente perdido).

Sabemos quién se va. Pero ¿qué aprendió el modelo y cómo lo verificamos?

Made with GAMMA

04 · ESTRATEGIA COMERCIAL

4 acciones automáticas. ROI de 2,2×. Margen mínimo garantizado.

Motor de Decisión Automático

01
Cliente

02
Modelo RF

03
Prob. Churn

04
Riesgo + CLTV

05
Acción

06
ROI

Modelo Económico

C(n) = BASE × (1 + α)^n

donde α = 7% para modelos premium (A, B) y α = 10% para el resto.

Costes por revisión: 1% marketing + comisión marca (2%–8% según modelo).

Restricción: margen neto mínimo del 37% (30% concesionario + 7% marca).

Tabla de Acciones

Color	Acción	Regla	Descuento	Contacto	Conv.	ROI
🔴	Retención Premium	Alto riesgo + CLTV alto	30% C(n)	50 EUR	42%	0,7×
🟠	Retención Estándar	Alto riesgo + CLTV bajo/medio	22% C(n)	35 EUR	40%	0,7×
🟣	Fidelización Activa	Riesgo medio	15% C(n)	20 EUR	38%	1,3×
🟢	Mantenimiento Preventivo	Riesgo bajo	8% C(n)	10 EUR	50%	3,8×

Revenue at Risk por Segmento

Segmento	Clientes	CLTV Total	Revenue en Riesgo
Bajo	6.241	12.556.932 EUR	1.546.267 EUR (12,3%)
Medio	2.060	3.452.128 EUR	1.373.611 EUR (39,8%)
Alto	1.699	2.685.863 EUR	1.583.827 EUR (59,0%)
TOTAL	**10.000**	**18.694.922 EUR**	**4.503.706 EUR (24,1%)**

Análisis de Sensibilidad del Threshold

Threshold	Clientes Alto Riesgo	% Cartera	Inversión	Rev. Risk Capturado
0,30	3.759	37,6%	545.104 EUR	2.957.439 EUR (65,7%)
0,40	2.731	27,3%	496.302 EUR	2.345.366 EUR (52,1%)
0,50 ★	**1.699**	**17,0%**	**447.311 EUR**	**1.583.827 EUR (35,2%)**
0,60	734	7,3%	401.500 EUR	—

KPIs Globales

547K
Inversión Total
En acciones de retención

2.2x
ROI Global
Ajustado por conversión

76.9%
Margen Neto
Medio por operación

CLTV medio por cliente: 1.869 EUR (horizonte 5 revisiones). CLTV total cartera: 18.694.922 EUR.

Made with GAMMA

05 • PRODUCTO FINAL

De modelo académico a herramienta real desplegada en producción

Tabs del Dashboard

01

Resumen

KPIs globales, distribución de riesgo, churn por modelo

02

Explorador

Ficha cliente + SHAP waterfall + Simulador What-If (11 variables)

03

Estrategia

ROI por acción, CLTV por modelo, comparador de escenarios A/B

04

Sensibilidad

Ajuste de threshold en vivo, impacto de descuentos por acción

05

Piloto Auto

Sube CSV → predice → descarga Excel con estrategia comercial

06

Modelo

Curva ROC, curva Precision-Recall, matriz de confusión, top features

Stack Tecnológico

Python 3.11	scikit-learn
SHAP	Plotly
Streamlit	GitHub

Resumen Ejecutivo

10K
Clientes Analizados

4
Modelos Comparados
LR, DT, RF, XGBoost

64
Features en Producción

1.7K
Alto Riesgo
Threshold 0,50

2.2x
ROI Global

76.9%
Margen Neto

Limitaciones Honestas

Precisión del 34%

Mejorable con datos de CRM e histórico de comunicaciones

Dataset de Staging

Tiene 0 revisiones previas (clientes nuevos) — limita reglas de fidelidad

Validación A/B

Pendiente en producción para medir impacto real

Recalibración

Recomendada cada 6–12 meses para detectar data drift

Por cada euro invertido en retención, recuperamos 2,2 EUR en margen de mantenimiento

Acceso al Dashboard

churn-prediction-automotive-jhxywrrmnkg5nfba3vxsxk.streamlit.app

Dashboard interactivo en vivo · accesible desde cualquier navegador

Made with GAMMA

Gracias

¿Preguntas?

Dashboard

churn-prediction-automotive-jhxywrrmnkg5nfba3vxsxk.streamlit.app

GitHub

github.com/PabloJimenezGirardeau/churn-prediction-automotive

Caso Práctico de Inteligencia Artificial · Universidad Alfonso X el Sabio · 2026

Made with GAMMA